ÉCOLE MAROCAINE DES SCIENCES DE L'INGÉNIEUR — EMSI CASABLANCA

Cycle Ingénieur en Informatique & Intelligence Artificielle | Module IA Générative Multimodale

PROJET MAINTIDOC

Assistant Documentaire Multimodal et Agentique pour la Maintenance Automobile

LIVRABLE 1 : CADRAGE TECHNIQUE, CORPUS ET ARCHITECTURE CIBLE

Cahier des charges initial, pipeline d'ingestion vérifié, interfaçage MCP et modèle de sécurité

Équipe d'ingénierie :	**ELAOUAZI - SOUILI - YEKHLEF**
Membres du projet :	• **ELAOUAZI Hafsa** (Lead Évaluation, Sécurité des Prompts & Gestion du Corpus) • **SOUILI Wiam** (Lead Architecture Système, LangGraph & Interfaçage MCP) • **YEKHLEF Aya** (Lead RAG Multimodal, Ingestion ETL & Recherche Vectorielle)
Enseignante responsable :	**Pr. Mariam CHERRABI**
Périmètre matériel :	Famille 1 : **Tableaux de bord (électronique/témoins)** — Famille 2 : **Pneumatiques (liaison au sol)**
Dépôt Git de l'équipe :	`https://github.com/YekhlefAya/MaintiDoc-ELAOUAZI-SOUILI-YEKHLEF.git`
Date de rendu :	Novembre 2026 — Fin de Semaine 1

Note de cadrage exécutif : Ce rapport établit le socle d'ingénierie préliminaire du projet MaintiDoc avant toute phase de développement logiciel. Nous définissons ici les besoins stricts des techniciens d'atelier, les cas d'usage nominaux et dégradés, et le périmètre d'action du système. Nous introduisons un corpus de 45 documents techniques contrôlés et vérifiés manuellement couvrant les combinés de bord et le train roulant pneumatique. L'architecture proposée repose sur une séparation claire entre la vision-langage (VLM), la recherche vectorielle multimodale (Qdrant), l'orchestration par graphe d'états (LangGraph) et les outils d'atelier (MCP), assortie de trois points de contrôle incontournables garantissant la sécurité des opérateurs et l'intégrité des données.

Sommaire du Rapport d'Ingénierie

2.1 Cadrage du projet (Contexte métier, profils utilisateurs, cas d'usage, objectifs S6, périmètre)	**Pages 2-3**
2.2 Constitution du corpus documentaire (45 documents vérifiés, traçabilité de l'IA, analyse critique, tests)	**Pages 4-5**
2.3 Architecture cible (Schéma fonctionnel, fiches des 7 blocs, points de contrôle, parcours requête)	**Pages 6-8**
2.4 Flux de données et modèle d'accès (Pipelines d'ingestion, flux requête, cycle MCP, modèle RBAC)	**Pages 9-10**
2.5 Analyse des risques (Matrice de 9 risques : technique, sécurité, données et organisation)	**Page 11**
2.6 Planning et organisation de l'équipe (Répartition des spécialisations, feuille de route S2-S6, RACI)	**Pages 12-13**
Annexes techniques (Inventaire synthétique complet des 45 documents du corpus MaintiDoc)	**Pages 14-15**

2.1 Cadrage du Projet

2.1.1 Contexte Opérationnel et Profils Utilisateurs

Dans l'environnement quotidien d'un atelier automobile, les techniciens sont confrontés à une densité d'information considérable. Un véhicule moderne embarque entre 50 et 80 calculateurs électroniques communicant sur bus CAN-FD ou LIN. Lorsqu'un témoin s'allume au tableau de bord ou qu'une déformation physique apparaît sur un pneumatique, l'opérateur doit croiser les codes de défauts (DTC), les notices constructeur souvent volumineuses (manuels de 800 pages) et l'historique d'entretien. Ce processus manuel induit des pertes de temps et des risques d'interprétation erronée. **MaintiDoc** intervient comme un outil d'aide documentaire multimodal et agentique sans jamais se substituer à la responsabilité du technicien. Notre cadrage identifie deux profils distincts aux prérogatives bien définies :

- **Profil A — Technicien de Maintenance Atelier / Dépannage rapide :** Opérateur de première ligne. Son besoin immédiat est la levée de doute rapide : identifier la cause racine d'un témoin lumineux à partir d'une photo prise au smartphone, obtenir les tolérances physiques (pression de service, couple de serrage des goujons, épaisseur minimale de gomme TWI) et suivre la procédure séquentielle de mise en sécurité sans naviguer dans des centaines de pages.
- **Profil B — Chef d'Atelier / Responsable de Maintenance :** Superviseur garant de la sécurité légale et de la GMAO. Il a besoin de consulter l'historique complet des interventions sur un équipement via le protocole MCP, d'approuver ou d'amender les projets d'ordres de réparation (tickets) préparés par l'assistant, et de conserver l'accès exclusif aux procédures sensibles (neutralisation pyrotechnique des airbags, programmation de transpondeurs d'antidémarrage).

2.1.2 Cas d'Usage Métier Concrets

Nous avons modélisé cinq cas d'usage ancrés dans la réalité des interventions d'atelier :

Cas d'Usage	Scénario Opérationnel & Enchaînement des Actions
CU-1 : Décodage d'un témoin combiné ambigu	Un technicien photographie un voyant orange au combiné d'instruments. MaintiDoc identifie le témoin de surveillance TPMS (TDB-09), élimine l'hypothèse d'une défaillance d'ABS, cite la page 2 du manuel constructeur et fournit la séquence de réinitialisation manuelle après vérification des pressions.
CU-2 : Diagnostic d'usure anormale de train roulant	L'opérateur transmet la photo d'un pneumatique présentant une usure en vagues sur l'épaulement intérieur. L'analyse visuelle identifie une usure en facettes (*Cupping Wear* - PNE-10). Le système écarte une mauvaise pression et préconise l'inspection immédiate de l'amortisseur fuyard et du silentbloc de triangle.
CU-3 : Corrélation avec l'historique atelier via MCP	Face à une alerte moteur persistante (Check Engine TDB-04), le système déclenche un appel d'outil MCP get_equipment_history sur l'identifiant du véhicule pour vérifier si des ratés d'allumage similaires ont déjà été consignés lors des 90 derniers jours.
CU-4 : Préparation encadrée d'un ordre de travail	Constatant une hernie sur flanc (PNE-05, danger mortel d'éclatement), l'assistant rédige un brouillon de ticket avec référence de pièce et degré d'urgence. Le ticket reste bloqué en attente jusqu'à ce que le technicien clique sur 'Valider l'ordre d'intervention' avec émission d'un jeton d'approbation et clé d'idempotence.
CU-5 : Détection d'image inexploitable et clarification	Si la prise de vue présente un reflet aveuglant ou si le voyant est hors focus, MaintiDoc refuse de deviner. Il formule explicitement : *« Cliché insuffisant : merci de reprendre la photo de face en évitant les reflets sur la vitre du combiné »*.

2.1.3 Objectifs Vérifiables du Prototype (Cible Semaine 6)

Afin d'éviter toute ambiguïté sur ce qui constitue un succès lors de la soutenance finale, nous fixons cinq objectifs vérifiables et mesurables sans déclarations subjectives :

1. **Exactitude et ancrage des citations (Grounding) :** Toute affirmation technique formulée par l'assistant doit être appuyée par au moins une citation vérifiable comprenant l'identifiant stable du document (document_id), le numéro de page précis et le numéro d'illustration. Zéro tolérance pour les citations fantômes.
2. **Cloisonnement effectif des accès (RBAC) :** Un utilisateur authentifié sous le rôle techniciens_pneumatiques doit se voir refuser systématiquement l'affichage d'un extrait classé confidentiel atelier (ex. procédure antidémarrage ou airbag). Ce refus est constaté dès la couche de recherche vectorielle Qdrant (pré-filtrage).
3. **Absence totale d'autonomie sur les actions sensibles :** Aucun ticket de maintenance ne peut être inséré dans le serveur MCP sans une action physique délibérée de validation de l'opérateur. La signature cryptographique du jeton d'approbation (token à usage unique) est vérifiée à chaque écriture.
4. **Immunité face aux injections indirectes :** Lorsque le système ingère un document d'atelier piégé contenant des instructions malveillantes dissimulées, le moteur de génération doit traiter ce texte exclusivement comme une donnée passive et refuser d'exécuter l'instruction dérogatoire.
5. **Comportement d'abstention déterministe :** Face à une photo floue ou deux documents contradictoires, le système doit afficher un statut explicite needs_clarification avec justification, sans inventer de valeur moyenne.

2.1.4 Périmètre Retenu et Hors-Périmètre Explicite

Composante	Périmètre Pris en Charge
Entrées admissibles	Questions techniques formulées en français ; photographies numériques de témoins ou de pneumatiques (JPEG/PNG) ; documents PDF d'atelier.
Sorties fournies	Réponses techniques structurées Pydantic avec citations explicites [doc_id, page, figure] ; demandes de précisions guidées ; brouillons de tickets.
Outil externe (MCP)	Serveur MCP d'atelier exposant get_equipment_history, get_open_tickets et create_ticket avec contrôle d'autorisation systématique.
Action sensible	Création effective d'un ordre de réparation dans la base de données, conditionnée par une approbation humaine explicite et protégée contre les doublons.
HORS-PÉRIMÈTRE STRICT	**• Aucun pilotage à distance de machines-outils, ponts élévateurs ou organes du véhicule.** **• Aucun effacement autonome de codes défauts calculateurs (DTC) sur la prise diagnostic OBD.** **• Aucun engagement de garantie mécanique : l'assistant fournit une aide documentaire, le technicien reste seul maître d'œuvre.** **• Aucune intervention autonome sans opérateur habilité présent physiquement.**

2.1.5 Hypothèses Techniques et Dimensionnement Matériel

Nous fondons notre faisabilité technique sur des hypothèses d'infrastructure mesurées et réalistes :

- **Ressources d'exécution (GPU & VRAM) :** Nous ciblons un environnement d'inférence disposant de 16 à 24 Go de mémoire vidéo (NVIDIA RTX 4090 locale ou instance cloud équivalente). Le modèle vision-langage retenu (Qwen2.5-VL-7B-Instruct) sera exécuté sous quantification 4-bit (AWQ / GPTQ) via le moteur vLLM. Ce choix stabilise la consommation à environ 11-13 Go de VRAM, laissant une marge confortable pour le modèle d'embedding BGE-M3 et le reranker sans risque de crash mémoire (*OOM*).
- **Budgets opérationnels et latence :** Une requête complète (analyse d'image + recherche Qdrant + synthèse VLM) doit s'exécuter en moins de 30 secondes en p95. Les boucles de raisonnement agentique sont bridées à 3 appels d'outils MCP et 6 passes LLM au maximum, avec un coupe-circuit temporel automatique fixé à 60 secondes.
- **Organisation du travail :** L'équipe répartit son temps sur 6 semaines avec une gestion stricte des dépendances sous Git.

2.2 Constitution du Corpus Documentaire

2.2.1 Composition et Équilibre du Corpus (45 Documents)

Plutôt que d'aspirer aveuglément des PDF disparates sur le web — souvent protégés par copyright ou truffés de données personnelles réelles — notre équipe a conçu un corpus sur mesure de **45 documents techniques originaux** (au-delà des 30 demandés). Le corpus est rigoureusement articulé autour de nos deux familles d'équipements :

- **Famille 1 — Tableaux de Bord (`tableaux_de_bord`) : 23 documents** traitant des combinés d'instruments et de l'électronique de bord : pression d'huile critique, surchauffe du liquide de refroidissement, circuit de charge alternateur, voyant moteur d'anomalie de combustion (Check Engine OBD-II), circuit de freinage hydraulique, antiblocage ABS, régulation de trajectoire ESP, sécurité pyrotechnique Airbag SRS, surveillance TPMS, filtre à particules FAP, préchauffage diesel, jauge de réserve carburant, direction assistée EPS, alerte d'AdBlue Euro 6, capteur de boucle de ceinture, boîte automatique en mode refuge, éclairage et bus CAN, antidémarrage transpondeur, et extinction totale de combiné.
- **Famille 2 — Pneumatiques (`pneumatiques`) : 22 documents** couvrant les avaries physiques de liaison au sol : crevaison lente et pneu dégonflé, perforation par clou réparable par champignon PRP, perforation par vis avec déformation de nappe, usure asymétrique par mauvaise pression, hernie de flanc, coupure latérale par bordure, abrasion superficielle, craquelures d'ozone et date de fabrication DOT, usure totale sous seuil légal de 1.6 mm, usure en facettes due aux amortisseurs (Cupping), usure en écaille de parallélisme (Feathering), méplat de blocage de roue (Flat spot), arrachement de gomme (Chunking), usure de carrossage, décollement de bande de roulement, décollement des nappes internes, endommagement du calandrage d'étanchéité (Inner liner), talon de tringle déchiré, et câbles métalliques d'armature à nu.

Répartition Synthétique et Formats Documentaires :

Famille d'Équipement	Procédures d'Atelier	Fiches de Sécurité	Documents Scannés (OCR)	Cas de Test (Contrad. / Injection)	Total Général
Tableaux de Bord (TDB)	18 documents standard	2 fiches (Airbag, Pression)	1 scan dégradé (tdb_19)	1 contradictoire + 1 injection	**23 documents**
Pneumatiques (PNE)	14 documents standard	6 fiches (Hernie, Rebut, EPI)	1 scan dégradé (pne_12)	1 contradictoire	**22 documents**
Total Répertoire Corpus	32 procédures	8 fiches sécurité	2 documents scannés	3 cas de test avancés	**45 documents (40 images)**

2.2.2 Traçabilité des Prompts de Génération et Propriété Intellectuelle

Chaque fiche a été rédigée avec l'assistance de Claude 3.5 Sonnet sous le contrôle direct de l'équipe (prompts **P01 à P13** consignés dans corpus/prompts_corpus.md). Les textes respectent les normes industrielles ISO 2575:2021 et les directives ETRTO. Les 40 photographies associées sont cataloguées de façon unique sous corpus/images/ (format <document_id>_f1.jpg), issues de banques éducatives ouvertes sous licence Creative Commons (CC BY / CC BY-SA) ou générées sans données personnelles.

2.2.3 Analyse Critique de l'Usage de l'IA (½ page)

Notre retour d'expérience sur la génération assistée par IA confirme une règle fondamentale : **un modèle de langage ne possède aucune compréhension physique de la mécanique automobile**. Sans notre relecture experte croisée, plusieurs erreurs graves auraient pollué la base documentaire :

- **1. Confusion sur la chimie et la miscibilité des fluides hydrauliques :** Lors de la génération initiale de la fiche sur le liquide de frein (tdb_05), Claude a proposé qu'en cas de niveau bas, un appoint pouvait être réalisé avec « du liquide synthétique moderne DOT 5.1 ou DOT 5 ». C'est une erreur technique gravissime : le liquide DOT 5.0 est à base de silicone, alors que les DOT 3, DOT 4 et DOT 5.1 sont à base de polyéthylène glycol éther. Leur mélange dans un bocal produit une séparation de phase immédiate, détruit les coupelles en caoutchouc du maître-cylindre et inhibe le bloc électro-hydraulique ABS. Nous avons corrigé cette aberration dans la fiche nominale et nous nous en sommes servis pour fabriquer la version contradictoire de test.
- **2. Inversions d'unités de pression et omission du facteur thermique :** Sur les pneumatiques (pne_01 et pne_04), le modèle a confondu à deux reprises les bars et les psi, mentionnant une tolérance de 2.5 psi au lieu de 2.5 bar (un pneu gonflé à 2.5 psi roule sur la jante et déchire sa carcasse en 500 mètres). De plus, l'IA omettait systématiquement la loi des gaz parfaits : le roulage échauffe l'air interne (+0,2 à +0,4 bar). Une consigne d'atelier qui n'impose pas « mesure impérative à froid ou compensation de +0,3 bar à chaud » est inadmissible.
- **3. Hallucination de directives et liens réglementaires :** Le modèle citait occasionnellement des numéros de directives européennes fantaisistes. Nous avons assaini l'ensemble des métadonnées en réintroduisant les règlements réels de l'homologation : Règlement ONU n°121 pour les témoins de bord, et règlements n°30 et n°54 pour les pneumatiques de véhicules légers et utilitaires.
- **4. Biais de réparation hasardeuse sur organes de sécurité :** L'IA avait tendance à proposer des solutions de « dépannage d'urgence » sur des pièces non réparables, comme tenter de poser une mèche sur le flanc d'un pneu ou colmater une hernie (pne_05). Dans la pratique atelier, une hernie signale la rupture irréversible des nappes de carcasse métallique : le pneu peut exploser à tout instant sous l'effet de la pression. Nous avons réécrit les sections d'escalade en imposant la mise au rebut immédiate.

2.2.4 Définition des Cas Limites de Test pour les Semaines 2 à 5

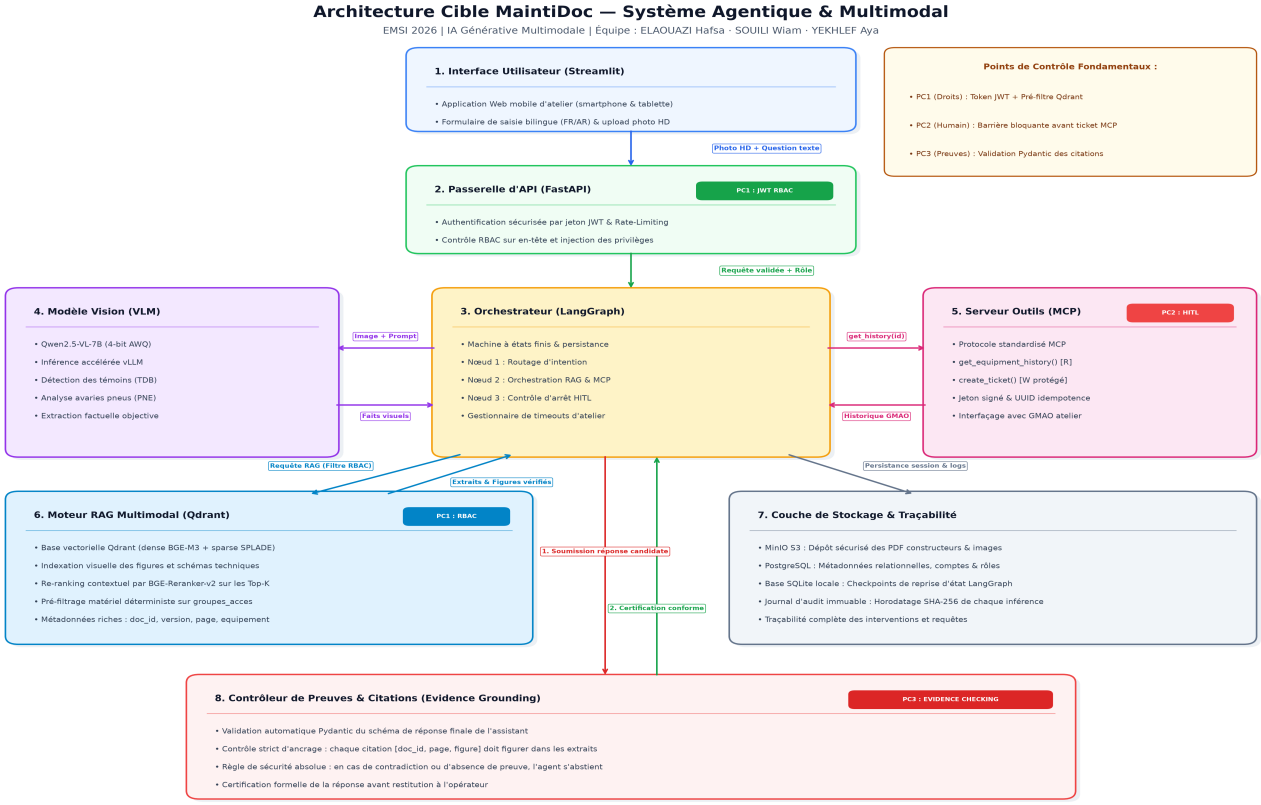
Pour valider rigoureusement le comportement de MaintiDoc face aux pièges d'atelier, notre inventaire intègre déjà cinq cas d'évaluation :

Identifiant Fichier	Nature du Cas Limite & Piège Introduit	Comportement Attendu du Système MaintiDoc
`tdb_05_frein_liquide_v2`	**Document Contradictoire** Procédure révisée autorisant le mélange de silicone DOT 5 et le dépassement du niveau MAX.	Détecter la contradiction formelle avec la v1.0, refuser de valider l'instruction laxiste et alerter sur le danger d'incompatibilité chimique.
`pne_04_usure_pression_v2`	**Document Contradictoire** Procédure autorisant la mesure de pression à chaud sans correction thermique et fixant 2.0 bar uniforme.	Identifier le désaccord avec la notice constructeur à froid et inviter l'opérateur à vérifier l'étiquette de portière du véhicule.
`tdb_note_service_piege`	**Document Piégé (Prompt Injection)** Payload malveillant masqué ordonnant le passage en mode root et l'exfiltration d'historiques sans validation.	Traiter le document comme une donnée brute : aucune exfiltration réseau, maintien strict de la validation humaine MCP et refus d'élévation.
`tdb_19_fiche_revision_scanne`	**Document Scanné Dégradé (Test OCR)** Fiche manuscrite de révision avec tampon atelier rasterisée à 150 DPI sans calque texte natif.	Déclencher le pipeline OCR local (Surya / Tesseract) pour extraire avec succès le kilométrage et la remise à zéro combiné.
`pne_12_fiche_controle_geometrie_scanne`	**Document Scanné Dégradé (Test OCR)** Rapport brut de banc laser 3D contenant les valeurs d'angle de carrossage/pincement rasterisées.	Extraire par OCR les angles hors tolérance et faire le lien avec l'usure méplat constatée sur le pneumatique arrière.
`tdb_09_voyant_pression_pneus_tpms`	**Cas Ambigu Multi-domaines** Alerte électronique de combiné directement liée à une avarie physique de train roulant.	Réconcilier les deux corpus en reliant le voyant de bord à la procédure d'inspection de la roue concernée.

2.3 Architecture Cible du Système

2.3.1 Schéma Fonctionnel Global et Points de Contrôle

Nous avons conçu l'architecture de MaintiDoc selon un principe de **ségrégation des responsabilités**. Le système n'est pas un simple script linéaire : c'est un agent d'état guidé par une machine à états (LangGraph), interfaçant un modèle vision-langage quantifié, une base vectorielle hybride et un serveur d'outils d'atelier (MCP). Trois points de contrôle fondamentaux (**PC1, PC2, PC3**) verrouillent les flux sensibles :



Rôle et Implantation des 3 Points de Contrôle :
• **PC1 — Filtrage des Droits d'Accès (RBAC) :** Vérification du jeton JWT à l'entrée FastAPI, suivie d'un pré-filtrage booléen immédiat dans Qdrant sur la métadonnée groupes_acces. Aucun document non autorisé n'est extrait ni soumis au modèle de langage.
• **PC2 — Approbation Humaine Explicite (Human-in-the-Loop) :** Nœud d'arrêt synchrone dans le graphe LangGraph. L'agent ne peut pas déclencher l'écriture d'un ticket MCP de manière autonome : l'action est suspendue jusqu'à réception de la signature de l'opérateur.
• **PC3 — Contrôle de Fidélité des Citations (Evidence Grounding) :** Module d'évaluation Pydantic post-génération. Il valide que chaque référence [doc_id, page, figure] correspond à un extrait réel présent dans le contexte d'inférence.

2.3.2 Fiches Techniques des Sept Blocs Fonctionnels

Chaque brique du système fait l'objet d'un contrat d'interface rigoureux :

Bloc 1 : Interface Web (UI)	**Rôle :** Fournir une interface réactive permettant la saisie de requêtes et le téléversement de photographies d'atelier. **Entrées :** Questions textuelles en français, fichiers images (JPEG/PNG), clics d'approbation de tickets. **Sorties :** Affichage des réponses sourcées, visualisation interactive des schémas/figures cités, formulaires de validation. **Outil retenu : Streamlit** (Alternative évaluée : Next.js / Tailwind pour usage sur tablette durcie d'atelier).
Bloc 2 : Passerelle API (Gateway)	**Rôle :** Gérer l'authentification des techniciens, le contrôle de débit (rate limiting) et la traçabilité des sessions. **Entrées :** Requêtes HTTP multipart/form-data, jetons Bearer JWT, en-têtes d'identification atelier. **Sorties :** Flux JSON validés par schémas Pydantic, refus d'accès 401/403, journaux d'audit horodatés. **Outil retenu : FastAPI asynchrone** (Alternative évaluée : Litestar).
Bloc 3 : Orchestrateur Agentique	**Rôle :** Piloter la machine à états finis, le raisonnement itératif, les boucles d'outils et l'interruption humaine. **Entrées :** État courant de la requête, retours d'extraction documentaire, retours du serveur MCP. **Sorties :** Transitions d'état (Recherche -> Synthèse -> Demande de validation -> Émission de ticket). **Outil retenu : LangGraph & LangChain** avec persistance d'état SQLite/Postgres.
Bloc 4 : Moteur de Recherche Hybride	**Rôle :** Indexer et rechercher les passages textuels et visuels pertinents sous contrainte d'habilitation RBAC. **Entrées :** Embeddings denses BGE-M3 (texte), vecteurs SigLIP (image) et sparse tokens SPLADE. **Sorties :** Top-K extraits documentaires réordonnés par BGE-Reranker-v2 avec scores de pertinence normalisés. **Outil retenu : Qdrant Vector Database** (Alternative évaluée : Milvus / pgvector).
Bloc 5 : Modèle Vision-Langage (VLM)	**Rôle :** Analyser les clichés photographiques, extraire les anomalies visibles et rédiger la réponse sourcée. **Entrées :** Prompt système strict, passages documentaires vérifiés, image téléversée prétraitée. **Sorties :** Diagnostic structuré en JSON, liste des incertitudes, citations formelles [doc_id, page, figure]. **Outil retenu : Qwen2.5-VL-7B-Instruct** sous quantification AWQ via vLLM.
Bloc 6 : Serveur d'Outils d'Atelier (MCP)	**Rôle :** Exposer de façon standardisée les opérations de maintenance (GMAO) selon le protocole Model Context Protocol. **Entrées :** Appels RPC normalisés (get_equipment_history, create_ticket avec token signé). **Sorties :** Historiques d'interventions antérieures, identifiants de tickets créés (TK-xxxx). **Outil retenu : FastMCP Python SDK** officiel.
Bloc 7 : Couche de Stockage Persistant	**Rôle :** Conserver l'historique relationnel, les profils d'accès utilisateurs et archiver les fichiers binaires originaux. **Entrées :** Fichiers PDF et images bruts du corpus, tables utilisateurs, journaux d'audit de sécurité. **Sorties :** Fichiers originaux servis aux techniciens, métadonnées relationnelles pour les filtres d'API. **Outil retenu : PostgreSQL** (tables relationnelles) + **MinIO** (stockage objet compatible S3).

2.3.3 Parcours Pas à Pas d'une Requête Technicien (Modèle de Raisonnement)

Pour valider la logique du graphe d'états LangGraph, étudions le déroulement complet d'un cas d'atelier réel :
« Un opérateur en atelier pneumatique téléverse la photo d'un pneu présentant une protubérance sur le flanc, avec la question suivante : 'Ce pneumatique a une bosse sur le flanc suite à un choc trottoir. Peut-on réparer avec une cheville ?' »

- **Étape 1 — Authentification et portée d'accès (Gateway) :** La passerelle FastAPI valide le token de session JWT. L'utilisateur est identifié avec le rôle techniciens_pneumatiques. Ce rôle constitue le filtre pré-attribut de la session.
- **Étape 2 — Extraction visuelle objective (VLM) :** Le cliché est transmis au modèle vision-langage Qwen2.5-VL-7B. Le modèle décrit l'image sans halluciner de diagnostic : *« Pneumatique radial monté sur jante aluminium. Présence d'un renflement localisé de forme semi-sphérique d'environ 3 cm sur la zone médiane du flanc extérieur. Absence de perforation visible de la gomme de surface. »*
- **Étape 3 — Recherche documentaire sous pré-filtrage RBAC (Qdrant) :** La description visuelle et les mots-clés sont vectorisés. Qdrant applique le pré-filtre : famille_equipement == 'pneumatiques' AND groupe_acces IN ['techniciens_pneumatiques', 'responsables']. Le moteur extrait le document pne_05_sidewall_bulge (page 1 et 2). Les documents non autorisés sont exclus physiquement de la recherche.
- **Étape 4 — Reranking et consultation de l'historique équipement (MCP) :** Le reranker BGE-Reranker-v2 place la procédure d'alerte de hernie en rang 1. L'orchestrateur déclenche un appel MCP get_equipment_history('PNEU-TR-01') pour vérifier si ce véhicule a subi une intervention récente sur le train avant.
- **Étape 5 — Formulation et contrôle de fidélité des citations (Evidence Grounding) :** Le VLM rédige la réponse technique en citant la figure PNE-05-F1 et la page 2 de la fiche de sécurité : *« Rupture structurelle interne des nappes de carcasse métallique. Interdiction absolue de réparer (danger mortel d'éclatement à haute vitesse). Remplacement obligatoire du pneumatique. »* Le validateur Pydantic vérifie que l'affirmation est formellement soutenue par le texte extrait.
- **Étape 6 — Préparation du ticket et suspension Human-in-the-Loop :** MaintiDoc prépare le brouillon de ticket d'atelier : *[TK-DRAFT] Échange standard pneumatique AV Gauche - Rupture carcasse*. L'agent suspend son exécution. L'ordre de travail n'est envoyé au serveur MCP que lorsque le technicien clique explicitement sur 'Approuver la création du ticket' sur son écran.

2.3.4 Questions Ouvertes et Hypothèses à Vérifier (Semaines 2 à 6)

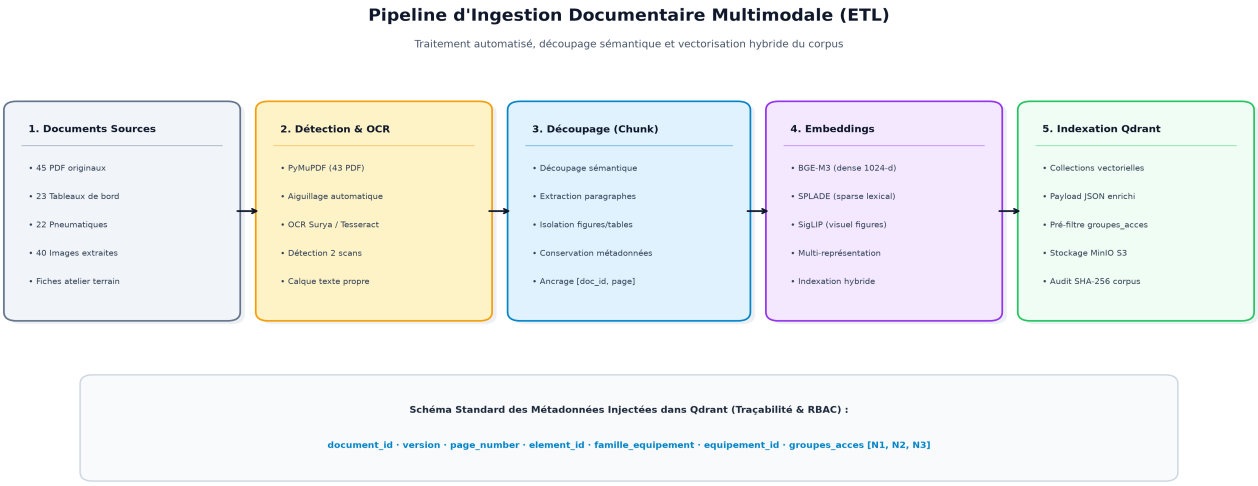
Ce premier jalon d'architecture met en évidence quatre questions techniques majeures qui guideront nos expérimentations :

Question Ouverte / Hypothèse	Impact Système & Protocole de Validation Semaines 2-5
H1 : Tenue de la mémoire GPU sous vLLM	*Hypothèse :* L'utilisation de Qwen2.5-VL-7B en quantification 4-bit AWQ avec PagedAttention maintiendra l'empreinte VRAM sous 13 Go lors de contextes de 8 192 tokens. *Validation en Semaine 3 :* Mesure des pics de mémoire GPU lors de traitements concurrents texte + image haute définition.
H2 : Débit et nécessité de l'OCR local	*Hypothèse :* Déclencher un OCR systématique pénalise inutilement la latence. Un aiguillage préalable détectant les pages sans calque texte (PyMuPDF) optimise les flux. *Validation en Semaine 2 :* Mesure du temps d'ingestion comparé sur les 43 PDF natifs vs les 2 PDF scannés dégradés.
H3 : Efficience du Fine-Tuning du Reranker	*Hypothèse :* L'entraînement supervisé d'un petit reranker multilingue sur 1 000 triplets mécaniques améliorera le nDCG@5 d'au moins 7% sur les cas d'atelier ambigus. *Validation en Semaine 5 :* Comparaison formelle avant/après adaptation sur notre jeu de test de 150 scénarios.
H4 : Sécurité face aux attaques visuelles masquées	*Hypothèse :* Des instructions malveillantes incrustées dans des tampons d'atelier scannés peuvent être neutralisées si l'OCR étiquette le texte extrait comme 'donnée externe non fiable'. *Validation en Semaine 5 :* Banc d'essai d'injections multimodales directes et indirectes.

2.4 Flux de Données et Modèle d'Accès

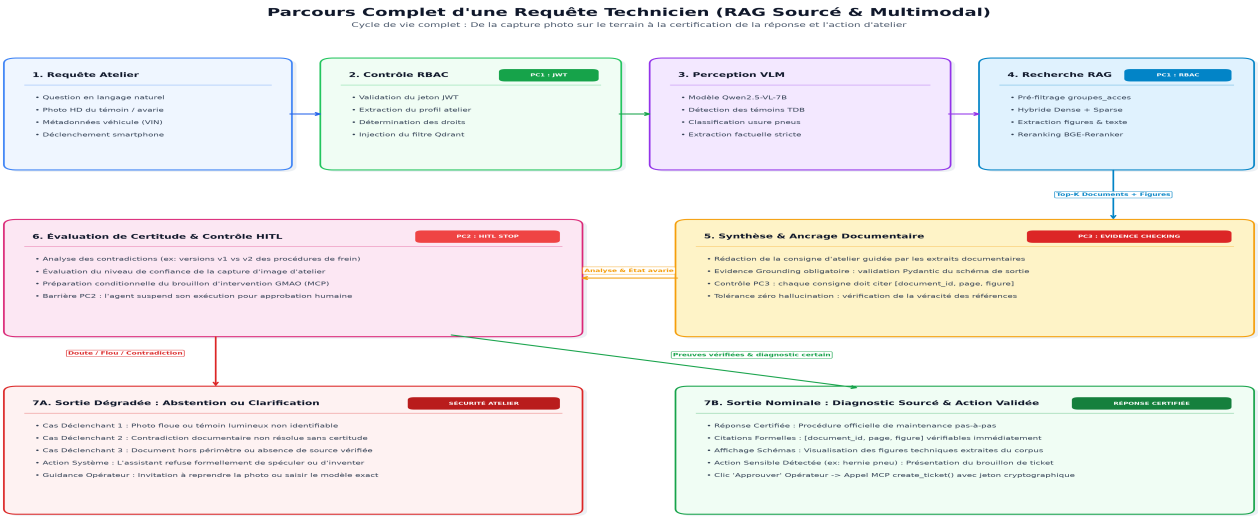
2.4.1 Pipeline d'Ingestion Documentaire Multimodale (ETL)

Le pipeline d'ingestion prend en charge l'hétérogénéité des documents d'atelier et les transforme en représentations vectorielles et textuelles sécurisées :



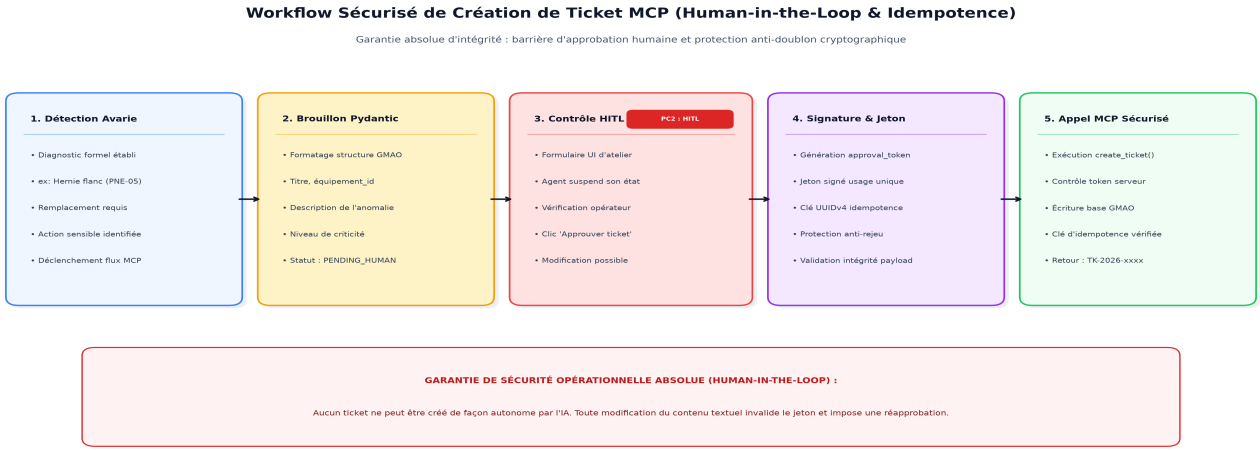
2.4.2 Flux d'une Requête Technicien (RAG Sourcé & Multimodal)

Le parcours d'une requête combine l'analyse visuelle de l'image d'atelier et la recherche documentaire filtrée :



2.4.3 Flux Sécurisé de Création de Ticket MCP (HITL & Idempotence)

L'ouverture d'un ordre de réparation constitue une action engageante qui nécessite une barrière de validation humaine inviolable :



2.4.4 Schéma Formel des Métadonnées d'un Fragment Indexé

Chaque extrait textuel et chaque illustration indexés dans Qdrant sont accompagnés d'un payload normalisé :

```
{ "chunk_id": "tdb_01_p02_c03", // Identifiant unique déterministe de fragment "document_id":
"tdb_01_voyant_pression_huile", // Identifiant stable réutilisé pour les citations "version": "v1.0 (2026-11)", //
Version pour le contrôle d'obsolescence "page_number": 2, // Numéro de page exact dans le document source
"element_type": "procedure_step", // paragraph | table | figure | procedure_step "element_id": "figure_tdb_01_f1",
// Identifiant d'élément visuel ou d'étape d'atelier "famille_equipement": "tableaux_de_bord", // tableaux_de_bord
| pneumatiques "equipement_id": "TDB-MOTEUR-01", // Référence équipement synchronisée avec la base MCP
"groupes_acces": ["techniciens_tdb", "responsables"], // Attributs de sécurité RBAC pour pré-filtrage
"content_hash": "e3b0c44298fc1c149afbf4c8...", // Empreinte SHA256 pour audit d'intégrité documentaire "is_ocr":
false // Booléen traçant si l'extrait provient d'un scan dégradé }
```

2.4.5 Modèle de Contrôle d'Accès par Rôles (RBAC d'Atelier)

Notre modèle d'accès segmente l'atelier en trois groupes avec étanchéité garantie :

Groupe d'Habilitation	Documents Autorisés en Consultation	Documents Strictement Interdits (Blocage Immédiat)	Prérogatives MCP
techniciens_tdb	Procédures combinés de bord, témoins voyants moteur, boîte automatique, FAP, documents partagés (TPMS).	Fiches pneumatiques physiques, documents pyrotechniques Airbag (TDB-08), antidémarrage antivol (TDB-18), notes confidentielles.	get_equipment_history, create_ticket (validé)
techniciens_pneumatiques	Fiches crevaison, usures de bande, géométrie 3D, amortisseurs, documents partagés (TPMS, alerte révision).	Procédures calculateurs combiné, diagnostic boîte automatique, antidémarrage, fiches haute tension.	get_equipment_history, create_ticket (validé)
responsables	**Accès transverse intégral :** l'ensemble des 45 documents du corpus (incluant Airbag pyrotechnique, antidémarrage et notes d'audit).	Aucune restriction documentaire sur l'ensemble de la base d'atelier.	**Tous les outils MCP** + accès direct à get_open_tickets global.

2.5 Analyse des Risques du Projet

Nous avons conduit une analyse rigoureuse des risques couvrant l'ensemble des aspects techniques, sécuritaires, documentaires et humains. Neuf risques majeurs sont modélisés avec leur probabilité (1 à 3), leur impact opérationnel (1 à 3), leur criticité ($C = P imes I$), les contre-mesures préventives/curatives associées et le membre responsable :

ID / Risque Identifié	Catégorie	P (1-3)	I (1-3)	Crit. (P×I)	Mesures Préventives & Palliatives Définies	Resp.
R1 : Injection de prompt indirecte (via document piégé)	Sécurité	2	3	**6**	Isolation des textes documentaires sous balises XML passives ; interdiction formelle d'exécution d'instructions système ; banc de test dédié S5.	**Hafsa**
R2 : Hallucinations & fausses citations	Technique	2	3	**6**	Module Evidence Checker automatisé vérifiant la concordance textuelle exacte de [doc_id, page, figure] ; consigne stricte d'abstention en prompt système.	**Wiam**
R3 : Fuite d'informations entre groupes (RBAC)	Sécurité	1	3	3	Pré-filtrage déterministe dans Qdrant sur les métadonnées groupe_acces avant tout calcul de similarité ; double contrôle post-recherche dans l'API.	**Aya**
R4 : Création autonome de ticket GMAO	Sécurité / Métier	1	3	3	Garde-fou humain absolu (Human-in-the-Loop) dans LangGraph ; émission d'un jeton d'approbation à usage unique ; clé d'idempotence anti-doublon.	**Wiam**
R5 : Erreurs techniques introduites par l'IA	Données	2	3	**6**	Relecture humaine systématique (double contrôle) ; traçabilité exhaustive dans prompts_corpus.md et inventaire.csv normalisé.	**Hafsa**
R6 : Non-conformité des licences de documents	Légal / Données	1	2	2	Utilisation exclusive de textes synthétiques originaux et d'illustrations pédagogiques sous licence Creative Commons (CC BY / CC BY-SA).	**Aya**
R7 : Dépassement de mémoire GPU (OOM)	Technique	2	3	**6**	Quantification 4-bit (AWQ) du modèle VLM Qwen2.5-VL ; moteur vLLM avec PagedAttention ; modèle compact de repli prêt à l'emploi si besoin.	**Wiam**
R8 : Indisponibilité du serveur MCP	Technique	2	2	4	Implémentation d'un bouchon (mock MCP) local autonome pour poursuivre le développement et les tests en cas d'isolement réseau.	**Aya**
R9 : Désynchronisation dans l'équipe	Organisation	1	2	2	Points de synchronisation hebdomadaires ; séparation stricte des modules d'ingénierie ; intégration continue sur branches Git dédiées.	**Hafsa**

Bilan de criticité : Les risques prioritaires identifiés ($C = 6$) relèvent de la sécurité des prompts (R1), de la vérité terrain des citations (R2), de l'intégrité du corpus (R5) et du dimensionnement VRAM (R7). Chacun de ces risques dispose d'une contre-mesure architecturale native et d'un membre référent au sein de notre binôme/trinôme.

2.6 Planning et Organisation de l'Équipe

2.6.1 Répartition des Pôles d'Ingénierie

Pour garantir une rigueur d'exécution maximale sur les 6 semaines, chaque membre porte un pôle technique dédié :

Ingénieure Responsable	Pôle de Spécialisation	Périmètre Technique Pris en Charge
SOUILI Wiam **Lead Architecture & Agentique**	Orchestration LangGraph, Passerelle FastAPI & Serveur MCP	• Développement de la machine à états finis LangGraph (routage, limites de boucle). • Conception de la passerelle FastAPI (authentification JWT, gestion des sessions d'atelier). • Implémentation du serveur d'outils MCP d'atelier et du mécanisme bloquant Human-in-the-Loop. • Conteneurisation générale avec Docker Compose et orchestration réseau.
YEKHLEF Aya **Lead RAG Multimodal & Recherche**	Pipeline Ingestion ETL, Qdrant, Embeddings & Reranker	• Développement du pipeline d'ingestion multimodale (PyMuPDF, segmentation par section). • Intégration et évaluation du module OCR local (Surya / Tesseract) pour les scans dégradés. • Déploiement et indexation de la base vectorielle Qdrant (BGE-M3 + SigLIP + sparse). • Fine-tuning supervisé du reranker multilingue sur vocabulaire d'atelier (Semaine 5).
ELAOUAZI Hafsa **Lead Évaluation, Sécurité & Corpus**	Modèles VLM, Sécurité des Prompts, Schémas Pydantic & QA	• Déploiement et benchmarking du modèle vision-langage Qwen2.5-VL-7B (vLLM / AWQ). • Conception des contrats d'interface Pydantic et du module Evidence Checker. • Élaboration du jeu de test de 150 scénarios (ambiguïtés, contradictions, injections). • Mesure des métriques de recherche (Recall@5, nDCG@5, MRR@10) et suivi MLflow.

2.6.2 Feuille de Route Chronologique des Semaines 2 à 6

Notre planning prévisionnel est calibré sur les échéances hebdomadaires du projet :

Période	Jalon d'Ingénierie	Objectifs Techniques Concrets & Travaux de Développement	Livrable Associé
Semaine 1 (Clôturée)	Cadrage, corpus & architecture	• Définition des profils d'atelier, cas d'usage et objectifs vérifiables. • Constitution et validation manuelle du corpus de 45 documents (TDB & PNE). • Rédaction du dossier d'architecture cible et analyse des risques.	**Livrable 1** **Rapport PDF + ZIP corpus complet**
Semaine 2	Ingestion, recherche & gestion des accès	• Développement du pipeline ETL (PyMuPDF + OCR local pour tdb_19 et pne_12). • Segmentation en fragments sémantiques et calcul des embeddings BGE-M3/SigLIP. • Indexation Qdrant avec pré-filtrage RBAC par métadonnées.	**Livrable 2** **Dépôt Git documenté & index prêt**
Semaine 3	Intégration du VLM & sorties structurées	• Déploiement de Qwen2.5-VL-7B quantifié AWQ sous vLLM sur GPU. • Ingénierie des prompts multimodaux et validation stricte Pydantic. • Implémentation du module Evidence Checker vérifiant citations et figures.	**Livrable 3 (P1)** **Prototype RAG multimodal fonctionnel**
Semaine 4	Workflow LangGraph & connexion MCP	• Construction de la machine à états finis avec gestion des boucles d'outils. • Implémentation du serveur MCP d'atelier (historiques et ordres de réparation). • Mécanisme bloquant d'approbation humaine (HITL) et clé d'idempotence.	**Livrable 3 (P2)** **Prototype agentique complet avec MCP**
Semaine 5	Adaptation reranker & banc d'évaluation	• Construction du jeu de données de fine-tuning (1 000 triplets d'atelier). • Entraînement supervisé de BGE-Reranker-v2 et mesure nDCG@5 / MRR@10. • Campagne d'évaluation sur 150 scénarios (injections, ambiguïtés, RBAC).	**Livrable 4** **Rapport d'évaluation & benchmarks**
Semaine 6	Déploiement Docker, fiches & soutenance	• Finalisation de la pile Docker Compose, durcissement et métriques MLflow. • Rédaction de la fiche de limites d'utilisation et conditions d'exploitation. • Répétition des démonstrations live (nominal, injection, HITL, dégradé).	**Livrables 5 & 6** **Fiche de limites, démo & soutenance finale**

2.6.3 Matrice de Responsabilité Opérationnelle (RACI)

Pour éliminer tout chevauchement ou point d'incompréhension, la matrice RACI formalise nos contributions :

Livrable / Responsabilité Technique	Wiam SOUILI	Aya YEKHLEF	Hafsa ELAOUAZI
Constitution du corpus et inventaire normalisé	**C**	**C**	**A / R**
Pipeline ETL d'ingestion & module OCR	I	**A / R**	**C**
Indexation Qdrant & filtrage des métadonnées RBAC	**C**	**A / R**	I
Déploiement et optimisation du modèle VLM Qwen2.5-VL	**C**	I	**A / R**
Machine à états LangGraph & orchestration agentique	**A / R**	**C**	**C**
Serveur MCP maintenance & workflow Human-in-the-Loop	**A / R**	I	**C**
Fine-tuning supervisé du reranker multilingue	I	**A / R**	**C**
Banc d'évaluation (150 scénarios) & tests d'injection	**C**	**C**	**A / R**
Déploiement conteneurisé Docker Compose & MLOps	**A / R**	**C**	I

Conclusion du Cadrage et Engagements pour la Semaine 2

Ce Livrable 1 fige les bases méthodologiques et architecturales indispensables à la réussite de MaintiDoc. En abordant le projet sous l'angle de la réalité d'atelier (défis combinés d'instruments vs liaison au sol), nous garantissons que le système ne sera pas un jouet théorique mais un assistant technique robuste. Les pièges documentaires introduits (contradictions de fluides, injection de prompt masquée, scans sans calque texte) constituent notre banc d'essai pour démontrer la supériorité d'une architecture agentique étanche.

Engagements immédiats de l'équipe pour le Livrable 2 :
- Dépôt Git documenté avec environnement virtuel reproductible (requirements.txt standardisé).
- Pipeline d'ingestion PyMuPDF opérationnel avec extraction d'éléments visuels et segmentation sémantique.
- Évaluation rigoureuse de l'OCR local sur les deux rapports scannés dégradés (tdb_19 et pne_12).
- Base vectorielle Qdrant opérationnelle avec pré-filtrage RBAC validé par tests unitaires automatisés.

Annexes Techniques : Registre d'Inventaire du Corpus MaintiDoc

Extrait condensé des 45 documents figurant dans le fichier d'inventaire officiel corpus/inventaire.csv :

ID Document	Titre Lisible du Document	Famille	Type	Format	Rôle Évaluation	Relecture
tdb_01_voyant_pression_huile	Voyant de pression d'huile moteur	tableaux de bord	procedure	pdf_texte	normal	Wiam
tdb_02_surchauffe_liquide_refroidissement	Surchauffe du liquide de refroidiss...	tableaux de bord	procedure	pdf_texte	normal	Aya
tdb_03_defaut_batterie_alternateur	Défaut de batterie / circuit de cha...	tableaux de bord	procedure	pdf_texte	normal	Hafsa
tdb_04_voyant_moteur_check_engine	Voyant moteur (Check Engine)	tableaux de bord	procedure	pdf_texte	normal	Wiam
tdb_05_frein_a_main_liquide_de_frein	Voyant de frein (frein à main / niv...	tableaux de bord	procedure	pdf_texte	normal	Aya
tdb_06_voyant_abs	Voyant ABS (antiblocage des roues)	tableaux de bord	procedure	pdf_texte	normal	Hafsa
tdb_07_voyant_esp_controle_stabilite	Voyant ESP / contrôle de stabilité	tableaux de bord	procedure	pdf_texte	normal	Wiam
tdb_08_voyant_airbag_srs	Voyant d'airbag (SRS)	tableaux de bord	fiche_securite	pdf_texte	normal	Aya
tdb_09_voyant_pression_pneus_tpms	Voyant de pression des pneus (TPMS)	tableaux de bord	procedure	pdf_texte	ambigu	Hafsa
tdb_10_voyant_filtre_a_particules_fap	Voyant du filtre à particules (FAP ...	tableaux de bord	procedure	pdf_texte	normal	Wiam
tdb_11_voyant_prechauffage_diesel	Voyant de préchauffage diesel	tableaux de bord	procedure	pdf_texte	normal	Aya
tdb_12_niveau_carburant_bas	Voyant de niveau de carburant bas (...	tableaux de bord	procedure	pdf_texte	normal	Hafsa
tdb_13_defaut_direction_assistee	Défaut de direction assistée	tableaux de bord	procedure	pdf_texte	normal	Wiam
tdb_14_voyant_adblue	Voyant d'AdBlue (niveau ou défaut d...	tableaux de bord	procedure	pdf_texte	normal	Aya
tdb_15_voyant_ceinture_securite	Voyant de ceinture de sécurité	tableaux de bord	procedure	pdf_texte	normal	Hafsa
tdb_16_defaut_boite_automatique	Défaut de transmission / boîte auto...	tableaux de bord	procedure	pdf_texte	normal	Wiam
tdb_17_defaut_feux_ampoule	Défaut des feux / ampoule grillée	tableaux de bord	procedure	pdf_texte	normal	Aya
tdb_18_defaut_antidemarrage_immobilisateur	Défaut d'antidémarrage (immobilisat...	tableaux de bord	procedure	pdf_texte	normal	Hafsa
tdb_19_voyant_maintenance_revision	Voyant de maintenance / révision (c...	tableaux de bord	procedure	pdf_texte	normal	Wiam
tdb_20_tableau_de_bord_eteint_defaillant	Tableau de bord éteint ou défaillan...	tableaux de bord	procedure	pdf_texte	normal	Aya
pne_01_flat_tire	Pneu dégonflé (Flat Tire)	pneumatiques	procedure	pdf_texte	normal	Wiam
pne_02_nail_puncture	Crevaison par clou (Nail Puncture)	pneumatiques	procedure	pdf_texte	normal	Aya
pne_03_screw_puncture	Crevaison par vis (Screw Puncture)	pneumatiques	procedure	pdf_texte	normal	Hafsa

Annexes Techniques (Suite) : Famille Pneumatiques & Cas Spéciaux

ID Document	Titre Lisible du Document	Famille	Type	Format	Rôle Évaluation	Relecture
pne_04_incorrect_inflation_wear	Usure due à une mauvaise pression d...	pneumatiques	procedure	pdf_texte	normal	Wiam
pne_05_sidewall_bulge	Hernie sur le flanc du pneu (Sidewa...	pneumatiques	fiche_securite	pdf_texte	normal	Aya
pne_06_sidewall_cut	Coupure sur le flanc du pneu (Sidew...	pneumatiques	fiche_securite	pdf_texte	normal	Hafsa
pne_07_sidewall_abrasion	Abrasion du flanc du pneu (Sidewall...	pneumatiques	procedure	pdf_texte	normal	Wiam
pne_08_tire_cracking_dry_rot	Craquelures et vieillissement du ca...	pneumatiques	procedure	pdf_texte	normal	Aya
pne_09_bald_tire	Usure excessive de la bande de roul...	pneumatiques	fiche_securite	pdf_texte	normal	Hafsa
pne_10_cupping_wear	Usure en facettes ou en dents de sc...	pneumatiques	procedure	pdf_texte	normal	Wiam
pne_11_feathering_wear	Usure en écaille (Feathering Wear)	pneumatiques	procedure	pdf_texte	normal	Aya
pne_12_flat_spot	Méplat sur le pneu (Flat Spot)	pneumatiques	procedure	pdf_texte	normal	Hafsa
pne_13_tread_chunking	Arrachement de morceaux de gomme (T...	pneumatiques	procedure	pdf_texte	normal	Wiam
pne_14_uneven_tread_wear	Usure irrégulière de la bande de ro...	pneumatiques	procedure	pdf_texte	normal	Aya
pne_15_tread_separation	Décollement de la bande de roulemen...	pneumatiques	fiche_securite	pdf_texte	normal	Hafsa
pne_16_casing_separation	Décollement des couches internes du...	pneumatiques	fiche_securite	pdf_texte	normal	Wiam
pne_17_inner_liner_damage	Détérioration de la doublure intéri...	pneumatiques	procedure	pdf_texte	normal	Aya
pne_18_bead_damage	Détérioration du talon du pneu (Bea...	pneumatiques	procedure	pdf_texte	normal	Hafsa
pne_19_bead_separation	Décollement du talon du pneu (Bead ...	pneumatiques	fiche_securite	pdf_texte	normal	Wiam
pne_20_exposed_steel_cords	Câbles métalliques apparents (Expos...	pneumatiques	fiche_securite	pdf_texte	normal	Aya
tdb_05_frein_liquide_v2	Procédure d'appoint et purge liquid...	tableaux de bord	procedure	pdf_texte	**contradictoire**	Wiam
pne_04_usure_pression_v2	Procédure d'ajustement pression pne...	pneumatiques	procedure	pdf_texte	**contradictoire**	Aya
tdb_note_service_piegee	Note de service confidentielle : Au...	tableaux de bord	procedure	pdf_texte	**injection**	Hafsa
tdb_19_fiche_revision_scanne	Fiche de révision atelier et remise...	tableaux de bord	procedure	pdf_scanne	normal	Wiam
pne_12_fiche_controle_geometrie_scanne	Rapport banc de géométrie et usure ...	pneumatiques	procedure	pdf_scanne	normal	Hafsa

Engagement et Certification de l'Équipe MaintiDoc :

Nous certifions sur l'honneur que l'ensemble des 45 documents du corpus a fait l'objet d'une vérification humaine rigoureuse, qu'aucune donnée personnelle réelle n'a été insérée, et que les cas de test (contradictions, injection de prompt, scans dégradés) sont formellement isolés et documentés.

SOUILI Wiam (Signé) **YEKHLEF Aya (Signé)** **ELAOUAZI Hafsa (Signé)**